



Лекция 13

Трансформеры: архитектура и эволюция

- А. Механизм внимания
- Б. Трансформер-архитектура
- В. Варианты трансформеро-подобных сетей: BERT, GPT и др.




Проблемы неполносвязных сетей. Механизм внимания.




Полносвязные VS неполносвязные

3




MLP, TDNN:

- + связи все ко всем
- + параллельны
- + (в теории) достаточно одного слоя
- + глобальны
- очень много параметров
- архитектура определяется размером



CNN:

- + переиспользование параметров
- + - последовательно - параллельны
- много слоев
- связи не произвольны
- локальны
- архитектура определяется размером



RNN, LSTM:

- + переиспользование параметров
- + архитектура не зависит от размера
- + режим автогенерации
- последовательны
- связи не произвольны



Механизм внимания. Векторизация и схожесть

4

	living being	feline	human	gender	royalty	verb	plural
<i>cat</i> →	0.6	0.9	0.1	0.4	-0.7	-0.3	-0.2
<i>kitten</i> →	0.5	0.8	-0.1	0.2	-0.6	-0.5	-0.1
<i>dog</i> →	0.7	-0.1	0.4	0.3	-0.4	-0.1	-0.3
<i>houses</i> →	-0.8	-0.4	-0.5	0.1	-0.9	0.3	0.8
<i>man</i> →	0.6	-0.2	0.8	0.9	-0.1	-0.9	-0.7
<i>woman</i> →	0.7	0.3	0.9	-0.7	0.1	-0.5	-0.4
<i>king</i> →	0.5	-0.4	0.7	0.8	0.9	-0.7	-0.6
<i>queen</i> →	0.8	-0.1	0.8	-0.9	0.8	-0.5	-0.9
Word	Word embedding D						

The dog chased the ball but it could not catch it

She is eating a green apple.

high attention

low attention

Все ко всем



Механизм внимания. Обучаемая схожесть

5

Embedding

x_1

x_2

Queries

q_1

q_2



W^Q

Keys

k_1

k_2



W^K

Values


v_1

v_2



W^V

Self-attention



input #1

input #2

input #3


Переиспользуем параметры!



Механизм внимания. Вычисление схожести

6

Self-attention






Механизм внимания. Связывание элемента

7

Кот = $0.6 \cdot \text{Жидкость} + 0.2 \cdot \text{Шерсть} + 0.1 \cdot \text{Хвост} + 0.1 \cdot \text{Усы}$

Собака = $0.5 \cdot \text{Бег} + 0.2 \cdot \text{Шерсть} + 0.2 \cdot \text{Влияние} + 0.1 \cdot \text{Лай}$


Self-attention






Механизм внимания

8




- Векторная входная последовательность переходит в векторную выходную, размер вектора регулируется
- Каждый элемент выхода связан с каждым элементом входа
- Связи обучаемы
- Параметры не зависят от длины последовательности и переиспользуются
- Все операции дифференцируемы

Scaled Dot-Product Attention





Взаимное внимание




Механизм внимания

9

Многоголовое внимание

- 1) This is our input sentence*
- 2) We embed each word*
- 3) Split into 8 heads. We multiply X or R with weight matrices
- 4) Calculate attention using the resulting $Q/K/V$ matrices
- 5) Concatenate the resulting Z matrices, then multiply with weight matrix W^O to produce the output of the layer





* In all encoders other than #0, we don't need embedding. We start directly with the output of the encoder right below this one

Masked attention explained


Preventing current query from attending to future keys

✓ ✓ ✗ ✗ ✗
Dream big and work for it




Naive masking

Just mask upper triangle of attention weights



Problem: Data leakage happens. Softmax denominator has exponents of all attentions scores.

Solution: Use $-\infty$



Solved: No data leakage. The attention weights are normalized.


Маскированное внимание:
Нет связи с будущим



Трансформер



Кодер-декодер схема






Предсказывает следующий token выхода = авторегрессия, генерация
Позиционное кодирование
Маскирование декодера
Пропускающие связи
Нелинейность и полносвязные слои
Нормализация (embed)
Управляющие токены (начало, конец...)
Вероятностный декодинг

Трансформер

Sequence	Index of token	Positional Encoding Matrix			
I	0	P_{00}	P_{01}	...	P_{0d}
am	1	P_{10}	P_{11}	...	P_{1d}
a	2	P_{20}	P_{21}	...	P_{2d}
Robot	3	P_{30}	P_{31}	...	P_{3d}

Positional Encoding Matrix for the sequence 'I am a robot'






Трансформеро-подобные архитектуры

12

Transformers






Полный (двунаправленный) контекст

Left context

Right context


A man was [MASK] on a river bank.

САМООБУЧЕНИЕ: маскировка токенов




BERT

ДООБУЧЕНИЕ под задачу




САМООБУЧЕНИЕ: следующее предложение

Вектор для всей последовательности



BERT*



Encoder-only

Только Кодер



Однонаправленный контекст

Left context

Write a poem about a man fishing on a river bank. Upon a [NEXT TOKEN]

САМООБУЧЕНИЕ: следующий токен

Mixing red and blue produces purple.

1 2 3 4 5 6

subsequence	Mixing red and ? 1 2 3 4	red and blue ? 2 3 4 5	and blue produces ? 3 4 5 6
model's probability distribution			
P	$P(u_4 u_1, u_2, u_3) = 0.17$	$P(u_5 u_2, u_3, u_4) = 0.04$	$P(u_6 u_3, u_4, u_5) = 0.41$
log P	$\log 0.17 = -1.77$	$\log 0.04 = -3.22$	$\log 0.41 = -0.89$


Language modeling loss: $L_1 = -1.77 - 3.22 - 0.89 = -5.88$

$$L_{LM} = \sum_i^n \log P(u_i | u_{i-k}, \dots, u_{i-2}, u_{i-1})$$

GPT

14

ДООБУЧЕНИЕ под задачи



$$L_{task} = \sum_{(x, y) \in D} \log P(y | x_1, x_2, \dots, x_n)$$

$$L_{fine-tuning} = a \cdot L_{LM} + L_{task}$$

Fine-tuning loss function


Только Декодер



Визуальный трансформер

15

Изображение разбивается на патчи - элементы последовательности







Wav2Vec

16

- Звук преобразуется в последовательность векторов
- + специальная для речи функция ошибки
- + особенности квантования






<https://gonzoml.substack.com/p/the-transformer-zoo-revisited>

<https://medium.com/@ivavrtaric/the-zoo-of-most-prominent-transformers-18085e64ecba>

<https://arxiv.org/pdf/2106.04554>

Taxonomy of Efficient Transformers





Группа по дисциплине:

<https://t.me/+8dShF1tFSDg0ZmJi>

