



Лекция 14

Векторные представления и поиск знаний (RAG)

- А. Вектора слов
- Б. Вектора текстов и речи
- В. Вектора изображений и др.
- Г. Векторные БД и RAG



Векторизация данных



Оцифровка – перевод в числовое представление

Символьное представление:

+ быстрота

+ простота и понятность


- произвол, смысл зависит от
нашего выбора

- длина

Буквы, цифры,
управляющие символы,
значки псевдографики и
т.п.

ASCII control characters			ASCII printable characters				Extended ASCII characters									
00	NULL	(Null character)	32	space	64	@	96	`	128	Ç	160	á	192	Ł	224	ó
01	SOH	(Start of Header)	33	!	65	A	97	a	129	ü	161	í	193	↓	225	ß
02	STX	(Start of Text)	34	"	66	B	98	b	130	é	162	ó	194	↑	226	À
03	ETX	(End of Text)	35	#	67	C	99	c	131	à	163	ü	195		227	Ó
04	EOT	(End of Trans.)	36	\$	68	D	100	d	132	ä	164	ñ	196	└─┘	228	ò
05	ENQ	(Enquiry)	37	%	69	E	101	e	133	â	165	Ñ	197	─┬─	229	Ô
06	ACK	(Acknowledgement)	38	&	70	F	102	f	134	ã	166	¸	198	└─┘	230	µ
07	BEL	(Bell)	39	'	71	G	103	g	135	ç	167	¸	199	─┬─	231	þ
08	BS	(Backspace)	40	(	72	H	104	h	136	ê	168	¸	200	└─┘	232	Û
09	HT	(Horizontal Tab)	41	)	73	I	105	i	137	ë	169	¸	201	└─┘	233	Ü
10	LF	(Line feed)	42	*	74	J	106	j	138	ì	170	¸	202	└─┘	234	Ý
11	VT	(Vertical Tab)	43	+	75	K	107	k	139	í	171	½	203	└─┘	235	Ú
12	FF	(Form feed)	44	,	76	L	108	l	140	î	172	¾	204	└─┘	236	Û
13	CR	(Carriage return)	45	-	77	M	109	m	141	ï	173	¸	205	└─┘	237	Ý
14	SO	(Shift Out)	46	.	78	N	110	n	142	Ä	174	«	206	└─┘	238	Ÿ
15	SI	(Shift In)	47	/	79	O	111	o	143	Å	175	»	207	└─┘	239	¸
16	DLE	(Data link escape)	48	0	80	P	112	p	144	Ê	176	¸	208	ð	240	±
17	DC1	(Device control 1)	49	1	81	Q	113	q	145	æ	177	¸	209	ð	241	±
18	DC2	(Device control 2)	50	2	82	R	114	r	146	Æ	178	¸	210	Ê	242	¸
Dec	Hex	Char	51	3	83	S	115	s	147	ö	179	¸	211	Ë	243	¾
			52	4	84	T	116	t	148	ö	180	¸	212	Ë	244	¾
			53	5	85	U	117	u	149	ö	181	¸	213	Ë	245	¾
			54	6	86	V	118	v	150	ü	182	¸	214	Ë	246	¾
			55	7	87	W	119	w	151	ü	183	¸	215	Ë	247	¾
			56	8	88	X	120	x	152	ÿ	184	¸	216	Ë	248	¾
			57	9	89	Y	121	y	153	Ø	185	¸	217	Ë	249	¾
			58	:	90	Z	122	z	154	Ø	186	¸	218	Ë	250	¾
			59	;	91	[	123	{	155	ø	187	¸	219	Ë	251	¾
			60	<	92	\	124		156	ø	188	¸	220	Ë	252	¾
102	66	f	61	=	93	]	125	}	157	Ø	189	¸	221	Ë	253	¾
103	67	g	62	>	94	^	126	~	158	x	190	¸	222	Ë	254	¾
104	68	h	63	?	95	_			159	f	191	¸	223	Ë	255	nbsps

Dec	Hex	Char	Dec	Hex	Char	Dec	Hex	Char	Dec	Hex	Char
0	00	Null	32	20	Space	64	40	@	96	60	`
1	01	Start of heading	33	21	!	65	41	A	97	61	a
2	02	Start of text	34	22	"	66	42	B	98	62	b
3	03	End of text	35	23	#	67	43	C	99	63	c
4	04	End of transmit	36	24	\$	68	44	D	100	64	d
5	05	Enquiry	37	25	%	69	45	E	101	65	e
6	06	Acknowledge	38	26	&	70	46	F	102	66	f
7	07	Audible bell	39	27	'	71	47	G	103	67	g
8	08	Backspace	40	28	(	72	48	H	104	68	h
9	09	Horizontal tab	41	29	)	73	49	I	105	69	i
10	0A	Line feed	42	2A	*	74	4A	J	106	6A	j
11	0B	Vertical tab	43	2B	+	75	4B	K	107	6B	k
12	0C	Form feed	44	2C	,	76	4C	L	108	6C	l
13	0D	Carriage return	45	2D	-	77	4D	M	109	6D	m
14	0E	Shift out	46	2E	.	78	4E	N	110	6E	n
15	0F	Shift in	47	2F	/	79	4F	O	111	6F	o
16	10	Data link escape	48	30	0	80	50	P	112	70	p
17	11	Device control 1	49	31	1	81	51	Q	113	71	q
18	12	Device control 2	50	32	2	82	52	R	114	72	r
19	13	Device control 3	51	33	3	83	53	S	115	73	s
20	14	Device control 4	52	34	4	84	54	T	116	74	t
21	15	Neg. acknowledge	53	35	5	85	55	U	117	75	u
22	16	Synchronous idle	54	36	6	86	56	V	118	76	v
23	17	End trans. block	55	37	7	87	57	W	119	77	w
24	18	Cancel	56	38	8	88	58	X	120	78	x
25	19	End of medium	57	39	9	89	59	Y	121	79	y
26	1A	Substitution	58	3A	:	90	5A	Z	122	7A	z
27	1B	Escape	59	3B	;	91	5B	[	123	7B	{
28	1C	File separator	60	3C	<	92	5C	\	124	7C	
29	1D	Group separator	61	3D	=	93	5D	^	125	7D	~
30	1E	Record separator	62	3E	>	94	5E	_	126	7E	
31	1F	Unit separator	63	3F	?	95	5F	`	127	7F	



a	d	r	e	s	s	.	u	r	l	/	p	a	g	e	1	2	3	4	5
---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---	---



Тексты как последовательности слов

4

Минимальная осмысленная единица – «слово»


Также допустимы:

- Части слов
- Словосочетания
- Наборы символов

Словарь

Sentence: Word embedding represents a word as numerical data.

vocabulary	word	[1, 0, 0, 0, 0, 0, 0]
	embedding	[0, 1, 0, 0, 0, 0, 0]
	represents	[0, 0, 1, 0, 0, 0, 0]
	a	[0, 0, 0, 1, 0, 0, 0]
	as	[0, 0, 0, 0, 1, 0, 0]
	numerical	[0, 0, 0, 0, 0, 1, 0]
	data	[0, 0, 0, 0, 0, 0, 1]



По результатам исследования одного английского университета, не имеет значения, в каком порядке расписаны буквы в слове. Главное, чтобы первая и последняя буквы были на месте. Остальные буквы могут располагаться в любом беспорядке, все равно текст читается без проблем. Понимание этого является тем, что мы не читаем каждую букву по отдельности, а все слово целиком.





Контекст слов

5

Похожий смысл = похожее употребление

Предсказать!




Мама мыла

раму
панаму
окно
сиреневый



Архитектура CBOW (единичный контекст)


6





Архитектура CBOW (общий случай)


7





Архитектура Skip-gram

8





Обучение

9

Исходный текст

Русский медленно запрягает да быстро едет

Русский медленно запрягает да быстро едет

Русский медленно запрягает да быстро едет

Русский медленно запрягает да быстро едет

Тренировочные сэмплы

(русский, медленно)
(русский, запрягает)

(медленно, русский)
(медленно, запрягает)
(медленно, да)


(запрягает, медленно)
(запрягает, да)
(запрягает, быстро)

(да, запрягает)
(да, быстро)
(да, едет)



Обучение


10





Вектора слов


11






Сравнение векторов

12



Male-Female



Verb tense

Косинусная похожесть

$$\text{similarity}(A, B) = \frac{A \cdot B}{\|A\| \times \|B\|} = \frac{\sum_{i=1}^n A_i \times B_i}{\sqrt{\sum_{i=1}^n A_i^2} \times \sqrt{\sum_{i=1}^n B_i^2}}$$



Примеры задач

13

Полезны сами по себе, например, для поиска синонимов или опечаток в поисковых запросах

Также могут быть использованы для решения ряда задач:

- выявление именованных сущностей
- тэгирование частей речи
- машинный перевод
- кластеризация документов
- ранжирование документов
- анализ тональности текста

Word: преключение

— приключение 0.748698

преключения 0.726111

приключения 0.692828

приключеия 0.670168

прключение 0.666706

приключеня 0.663286

прключения 0.660438

приключени 0.659609



Векторное представление GloVe

Матрица взаимной встречаемости слов

14

$$F(w_i, w_j, \tilde{w}_k) = \frac{P_{ik}}{P_{jk}}$$

The fast cat wears no hat

The cat in th4 hat ran fast

	cat	fast	hat	in	no	ran	the	wears
cat	0							
fast	2	0						
hat	2	2	0					
in	1	1	1	0				
no	1	1	1	0	0			
ran	1	1	1	1	0	0		
the	3	3	3	2	1	2	1	
wears	1	1	1	1	1	0	1	0

Контекст глобален



Функция ошибки

15

слово



Вектор $\mathbf{w}$, смещение $\mathbf{b}$

Встречаемость слов



Аппроксимация скалярным произведением векторов

$$J = \sum_{i,j=1}^V f(X_{ij}) (w_i^T \tilde{w}_j + b_i + \tilde{b}_j - \log X_{ij})^2$$

Probability and Ratio	$k = solid$	$k = gas$	$k = water$	$k = fashion$
$P(k ice)$	1.9×10^{-4}	6.6×10^{-5}	3.0×10^{-3}	1.7×10^{-5}
$P(k steam)$	2.2×10^{-5}	7.8×10^{-4}	2.2×10^{-3}	1.8×10^{-5}
$P(k ice)/P(k steam)$	8.9	8.5×10^{-2}	1.36	0.96


высокое низкое

Примерно одинаковое



Векторное представление fasttext

16





n-граммы

17





Векторные представления слов не из словаря

18




```
[>>> for word in model.get_nearest_neighbors('переобучилась'):
...     print(word)
...
(0.5939010977745056, 'обучилась')
(0.5761061310768127, 'переучилась')
(0.5460518002510071, 'покалечилась')
(0.5404532551765442, 'Обучился')
(0.5375197529792786, 'обучилось')
```



BERT и GPT

19



Вектор для всей последовательности





Вектора изображений


20







Вектора ... of everything

21




Paul	Steve	Mia
Mathematics	German	English
German	Mathematics	Physics
English	Physics	Geography

table







- regression
- classification
- similarity search
- outlier detection
- ...






Бектопа ... of everything

22



- regression
- classification
- similarity search
- outlier detection
- ...





Векторные БД

23


Заполнение базы

"I love
vector
databases"



contextualized
word embeddings

I	0.2	-1.7	...	2.3
love	0.4	0.5	...	-1.7
databases	4.1	-1.9	...	-1.5
	-1.1	0.7	...	5.3




Запрос

"Mountain
images"




0.2	-1.7	...	2.3
0.4	0.5	...	-1.7
4.1	-1.9	...	-1.5

Поиск



Match to
all vectors




0.2	-1.7	...	2.3
0.4	0.5	...	-1.7
4.1	-1.9	...	-1.5
-1.1	0.7	...	5.3
-3.5	2.3	...	0.5
-1.7	0.4	...	0.2
2.3	0.2	...	0.7
-1.9	4.1	...	-2.4
0.5	-1.5	...	2.3


flat index




Кластеризация



Поиск ближайшего центроида



Поиск внутри выбранного кластера




Flat Index




Search complexity: $O(ND)$

Step 1) centroids matching



Search complexity: $O(KD)$

Step 2) partition search



Search complexity: $O(ND/K)$




Векторные БД Product Quantization


25

Сегментация


256 dimensions




256 dimensions





Кластеризация для сегментов



Поиск ближайших центроидов



Заменяем сегмент на ID центроида




Было: 8192 (256*32). Стало: 64 (8 сегментов*8 бит) . x128 снижение памяти



Запрос

Сегментируем



Векторные БД


Product Quantization

26

PQ коды всех записей

1	1	1	1	1	1	1	1
27	11	1	21	8	2	7	1
14	0	10	16	2	16	4	10
8	29	17	26	24	24	18	9
12	15	3	4	12	19	2	31
19	2	2	7	0	6	9	12

Ищем близость к соответствующему центроиду



Сумма по всем сегментам = общее расстояние



Retrieval-Augmented Generation


27

Переобучение под запрос? Не думаю..

Слишком много... выбрать только релевантные = векторный поиск

Prompt

Tell me my
sales in the
last 10 days




Послать вероятно нужную информацию в запросе

Prompt

Tell me my
sales in the
last 10 days

prompt sent
to LLM



the team reported
sales of ...

The burn this
month was ...

⋮

Prompt

Tell me my
sales in the
last 10 days

encode

Prompt
vector

0.2, -1.2, ..., 2.3


fetch nearest
neighbor

find nearest
neighbor text

the team reported
sales of ...

The burn this
month was ...

⋮




vector
database of
unseen data



Unseen or new
information

Index


vector database






Retrieval-Augmented Generation


28




Сжатие



Нарезка



Мультивыбор



И др.



Группа по дисциплине:

<https://t.me/+8dShF1tFSDg0ZmJi>

