



Лекция 16

Мультимодальные модели

- А. Модальности данных
- Б. Уровни объединения: ViLBERT, CNN + RNN, LLaVA
- В. Пространство представлений: CLIP, BLIP2 (Qformer)
- Г. Другие модальности




Где мои данные, чувак?



2

Синтетика:

- аугментации – простые: слишком простые, сложные: сильно завязаны на знания предметной области
- персональные: нельзя просто так использовать персональные данные, нужно очень строгое обезличивание



Многоязычность: $I(\text{рассказ на одном языке}) < I(\text{тот же рассказ на нескольких языках})$

Многозадачность: $I(\text{перевод}) < I(\text{перевод и пересказ})$

Многомодальность: $I(\text{текстовая новость}) < I(\text{текстовая новость с картинками})$



Модальности данных

3

ТЕКСТ – простота, распространенность, легкая разметка.

Часто самая главная.

ИЗОБРАЖЕНИЕ – богата информацией, огромные объемы, стандартизация

АУДИО (речь) – потенциально более богатая, чем текст (для естественных языков), только-только начинает развиваться

Видео – вычислительно сложная

Таблицы (структуры) – парадокс, самая «старая» и одновременно трудно сочетаемая


3Д объекты – малое распространение

Сенсоры, тактильная – для роботов, медицина

Интерактивные

Вкус (?) - химическая и пищевая промышленность

Common Data Modalities in AI






Уровень, на котором происходит слияние

4

ViLBERT – слияние на уровне входных эмбеддингов






Уровень, на котором происходит слияние

5

CNN + RNN – слияние на уровне выходов






Уровень, на котором происходит слияние

6

Глубокий – специальные слои-проекторы – стандарт де факто

LLaVA Large Language-and-Vision Assistant






Пространство представлений


Единое – все вектора в одном пространстве

CLIP - Contrastive Language Image Pretraining

(1) Contrastive pre-training



<https://learnopencv.com/clip-model/>




7

ZeroShot classification:


Класс = слово

Найти наиболее похожее слово на картинку

(2) Create dataset classifier from label text



(3) Use for zero-shot prediction





Пространство представлений

Разные – используем проекторы для сопоставления пространств
+ не портим кодировщики


BLIP 2 (Qformer):

- обучаемые визуальные эмбединги (queries)
- кодировщик изображений, LLM – заморожены, предобучены
- BERT подобный адаптер - Qformer

1) Обучение извлечению
релевантных тексту
визуальных эмбедингов

2) Обучение генерации
релевантного ответа

Q нужны для инициализации, после обучения не используются.
В некоторых работах показано, что могут фокусироваться на определенных визуальных шаблонах.
В дальнейшем используются Z – выходы для Q.






Пространство представлений

Стадия 1 – обучение визуальных эмбеддингов под текст:




- две части: визуальный трансформер с взаимным вниманием с (замороженным) кодером изображения; текстовый трансформер для описания изображения. Предобучены, проинициализированы BERTом. Веса слоев внимания одинаковы.

Три задачи (ошибки):

- 1) Image-Text Contrastive Learning: соответствие изображения и его описания (как CLIP).
- 2) Image-grounded Text Generation: по визуальным эмбеддингам генерировать текст (как GPT)
- 3) Image-Text Matching: бинарный классификатор является ли текст описанием изображения или нет (практически как в BERT для предсказания продолжения предложения)



Q: query token positions; T: text token positions.
■ masked □ unmasked





Пространство представлений

10

Стадия 2 – обучение генерации:

- Z проецируются в входные эмбединги (читай «мягкий визуальный промпт») с помощью проектора
- LLM заморозена, предобучена,
- обучается (только проектор) генерации ответов (т.е. следующего токена).


Два варианта:

1) только декодер:

визуальный промпт = вопрос,
текст описания картинки = ответ

2) кодер-декодер:

визуальный промпт + префикс текста = вопрос,
суффикс (оставшийся текст) = ответ






Другие модальности

11

Whisper – речь + текст






Другие модальности

12

Qwen3 VL– текст + изображение+ видео








Другие модальности

13

OVLM — Olfaction-Vision-Language Model: запах - полноценная модальность






Другие модальности

14

HapticLLaMA: вибрации как модальность





За кадром

15

- маршрутизация (MoE) – обучаемые роутеры, которые выбирают какую ветку вычислений для модальностей использовать
- генеративное обучение модальностей: по одной модальности восстановить другую
- частичный перенос модальностей (обогащение): только небольшой процент данных модальностей связан. Пример: поведение покупателей на маркетплейсе в зависимости от их предпочтений в музыке

и многое другое



Группа по дисциплине:

<https://t.me/+8dShF1tFSDg0ZmJi>

